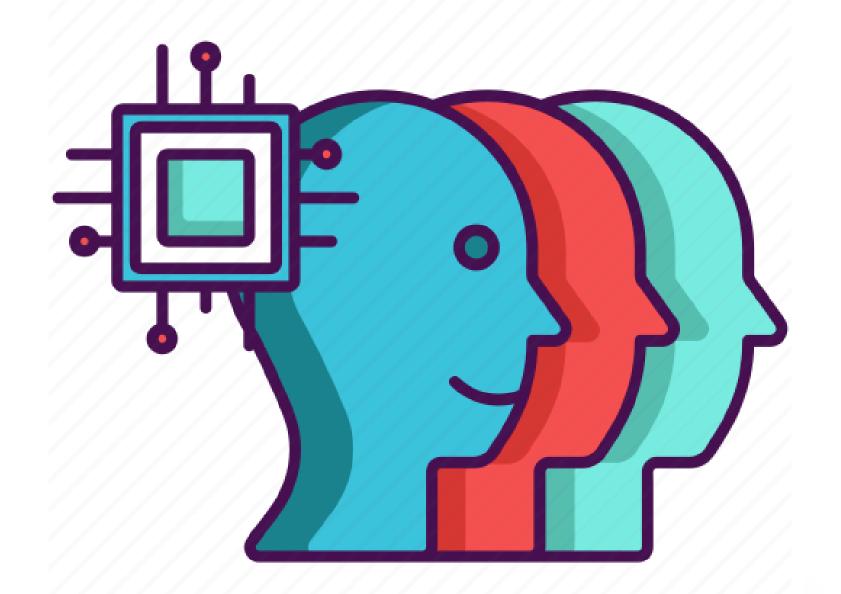


VALDOM 2025

Projet LLMengineering

Groupe 1
Abdoulaye Syll
Abdelali El Harrani





Sommaire



- 1. Introduction
- 2. Objectif du projet
- 3. Approche et méthodologie
- 4. Base de référence
- 5. Défis rencontrés et solution apportées
- 6. Outils développés et innovations
- 7. Tentatives infructueuses et leçons apprises
- 8. Démo en direct
- 9. Travaux futurs et améliorations possibles
- 10. Conclusion





Introduction

- Développement d'un agent web à l'aide de smolagents dans le but d'extraire des informations d'un site web.
- Mise en place d'un agent dédié à la recherche dans les fichiers CSV avec langchain





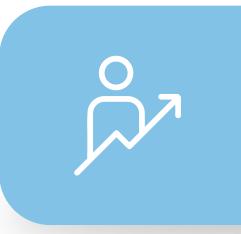
Objectifs du projet

 L'intérêt de l'agent web est de permettre d'extraire facilement des informations à partir d'un site web donné



Web agent

 L'agent csv à pour but de rendre possible la recherche et l'exploitation rapide d'informations à partir de fichiers csv



CSV agent





Séparation des approches : web et data

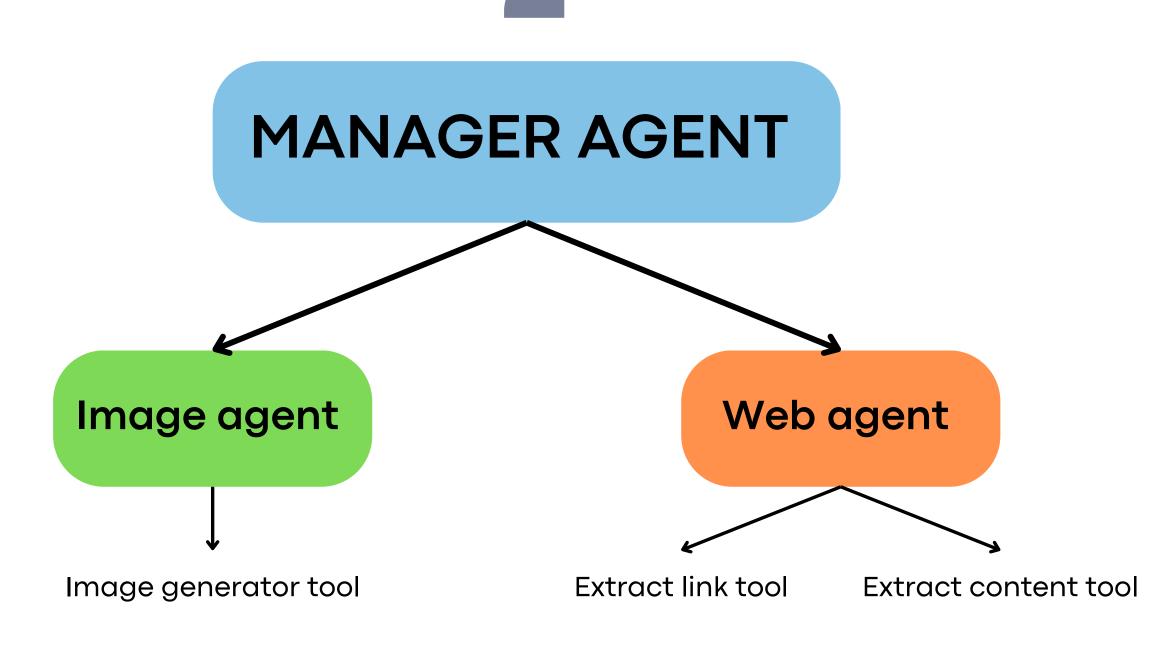
- Web search : interagir dynamiquement avec un site web pour répondre à des questions précises. Deux manières d'aborder le problème : navigation par extraction de contenu et navigation par analyse de capture d'écran. Stratégies de prompt précises pour guider l'agent dans ces tâches.
- Data search : répondre à des questions nécessitant plusieurs actions sur les données. Analyse dynamique de la structure des fichiers pour identifier puis manipuler les données pertinentes.





Web agent partie 1

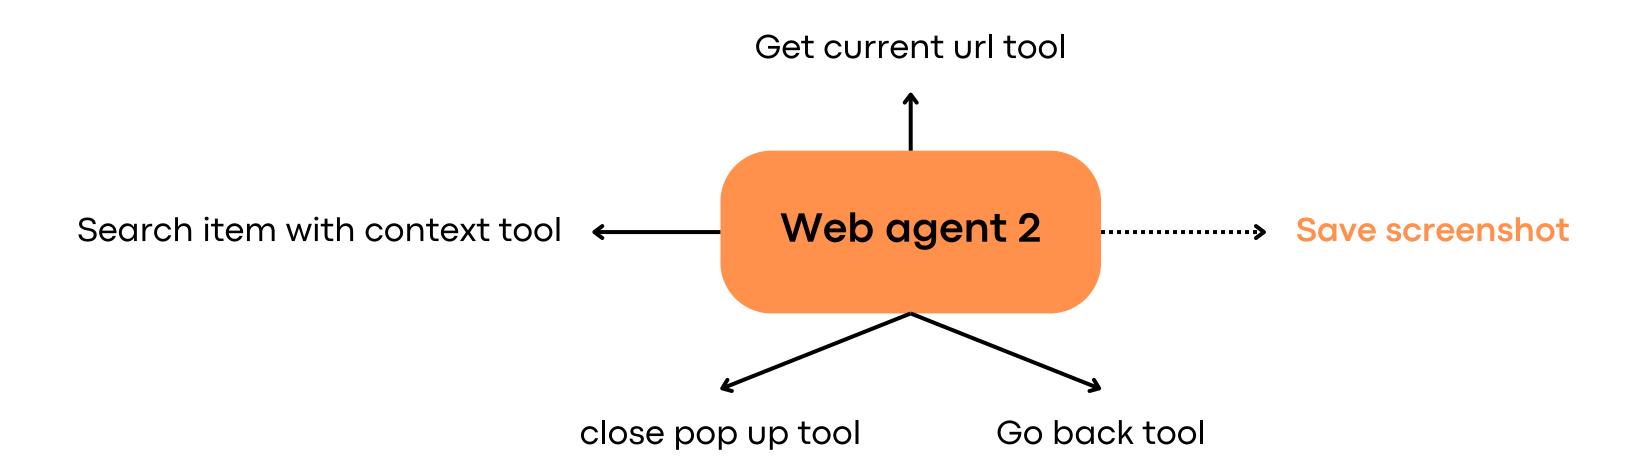
Web agent Extract link tool **Extract content tool**







Web agent partie 2



- gestion de la navigation avec helium/selenium
- firefox + geckodriver





Data agent

- 1) gestion d'un seul fichier
- 2) gestion de plusieurs fichier simultanément

JSON RAG CSV agent langchain create_csv_agent • BM25 Hybride





Réussites vs échecs

Web agent 2

Web agent 1

Réponses justes à des questions précises vérifiables en navigant sur le site

Captures d'écran non prise en comptes pour la navigation et l'extraction d'informations

Mauvais contexte retrieved et

CSV agent mauvaises réponses à des questions simples

JSON RAG

Réponses justes à des questions précises nécessitant la recherches dans plusieurs fichiers



Perspectives d'amélioration

- Intégrer un meilleur moteur d'indexation pour accélérer les recherches sur de très grands fichiers.
- Créer une interface utilisateur interactive permettant une utilisation plus intuitive de l'agent (ex : gradio UI).
- Tester CrewAI (framework plus mature et de nombreux outils à disposition) et comparer les résultats avec smolagents.
- Faire fonctionner les deux approches qui ont échoué.
- Mettre en place des métriques d'évaluations sur des ensembles de test
- Combiner les deux approches pour le moment séparées pour créer un système multi-agent pouvant traiter à la fois la navigation syr site web et des données





Conclusion et limites

- Smolagents et langchain sont des outils puissants mais très récents ce qui limite les cas d'usage
- Les méthodes mises en place ont montré des résultats prometteurs pour l'automatisation de l'extraction d'informations
- De nombreux axes d'amélioration ont été révélés : comparaison à CrewAl, combinaison des approches, ...
- Les outils développés fonctionnent dans un cadre fixé qui ne laisse pas de place à de la généralisation rapide à mettre en place



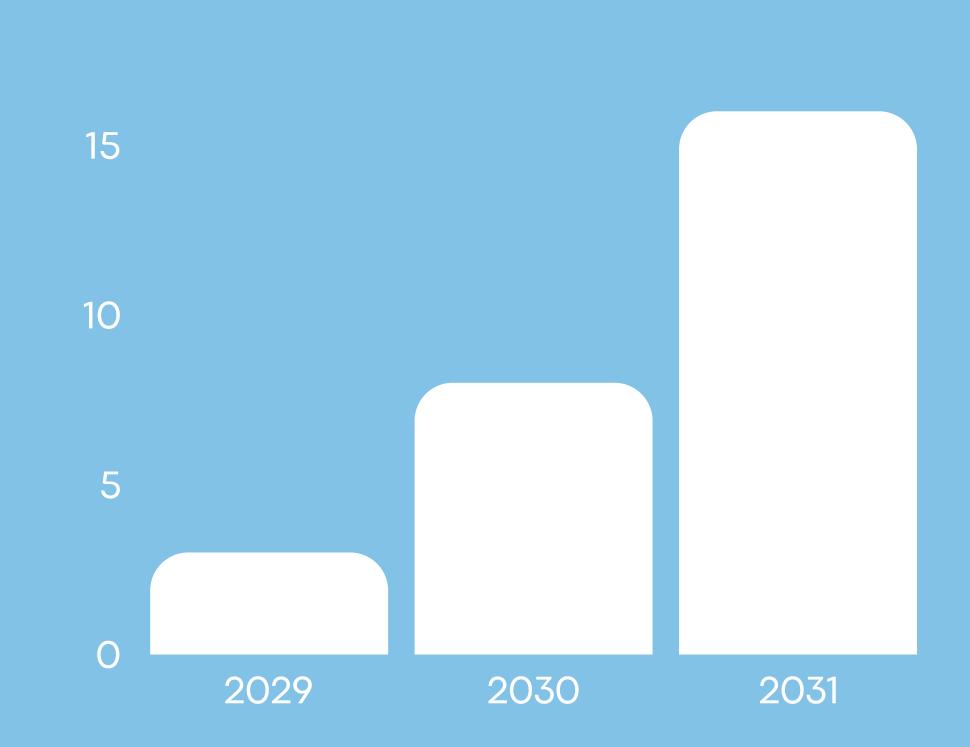


Merci pour votre attention





Demo



20